

Sprawozdanie z zadania 4 - Metody Probabilistyki i Statystyki

1. Celem pierwszego podpunktu pracy jest porównanie “ogonów” otrzymanych przy użyciu nierówności Markowa i Czebyszewa z dokładną wartością prawdopodobieństwa, obliczoną poprzez wykorzystanie pakietów matematycznych.

Rozważmy następującą zmienną losową X :

$$X \sim \text{Bin}(n, \frac{1}{2}).$$

Dla trzech wartości N :

$$N \in \{100, 1000, 10000\}$$

I następujących ogonów:

$$P(X \geq \frac{6}{5} E(X)) \quad (1)$$

$$P(|X - E(X)| \geq \frac{1}{10} E(X)) \quad (2)$$

Na początku zostaną przeprowadzone obliczenia teoretyczne dla pierwszego z prawdopodobieństw z użyciem nierówności Markowa:

$$P(X \geq a) \leq \frac{E(X)}{a}$$

Podstawiając otrzymujemy:

$$P(X \geq \frac{6}{5} E(X)) \leq \frac{E(X)}{\frac{6}{5} E(X)}$$

Skracamy:

$$P(X \geq \frac{6}{5} E(X)) \leq \frac{5}{6}$$

Otrzymany wynik w przyszłości porównamy z dokładną wartością.

Następnie ograniczenie drugiego z “ogonów” zostanie policzone nierównością Czebyszewa. Skorzystamy z przedstawionego na wykładach wzoru:

$$P(|X - E(X)| \geq k) \leq \frac{\text{var} X}{k^2}$$

Co więcej znając rodzaj rozkładu zmiennej losowej łatwo wyprowadzić wzór na wariancję:

$$\text{var}(X) = np(1 - p) \Rightarrow \text{var}(X) = \frac{n}{4}$$

Po podstawieniu wartości i wykonaniu odpowiednich skrótów dostajemy:

$$P(|X - E(X)| \geq \frac{1}{10} E(X)) \leq \frac{100}{n}.$$

Dokładne wartości prawdopodobieństwa obliczone zostały z wykorzystaniem załączonej klasy First. Używa ona odpowiednich pakietów matematycznych języka C++. Działanie programu opiera się na prawie wielkich liczb - brana jest losowa liczba z rozkładu $\text{Bin}(n, \frac{1}{2})$ (dla danego n). Każdy wynik, większy od $k * E(X)$ (gdzie k to wybrany współczynnik) jest odnotowywany. Następnie otrzymany "counter" dzielony jest przez liczbę prób. W poniższej tabeli przedstawione zostały wyniki tego eksperymentu.

| | Ograniczenie | Dokładna wartość N = 100 | Dokładna wartość N = 1000 | Dokładna wartość N = 10000 |
|------------|--------------|--------------------------|---------------------------|----------------------------|
| podpunkt A | 5% | 0,02844 | 0 | 0 |
| podpunkt B | 100/n | 0,27128 | 0,00173 | 0 |

Tabela 1. Wyniki dla Zadania 1.

Na podstawie tego zadania można wyciągnąć następujące wnioski:

1. Ograniczenie Markowa nie jest efektywne - w tym przypadku mogło by się okazać przydatne tylko dla $N \ll 100$.
2. W przeciwieństwie do ograniczenia Markowa, nierówność Czebyszewa działa najlepiej dla dużych liczb - widać, że im większa wartość N tym ograniczenie zbliża się do dokładnej wartości.

Podsumowując nierówność Markowa daje lepsze oszacowanie dla małych N , podczas gdy nierówność Czebyszewa sprawdza się dla dużych wartości.

2. Błądzenie losowe na liczbach całkowitych.

W drugim podpunkcie celem było przeanalizowanie błędzenia losowego na liczbach całkowitych i porównanie wyników z odpowiadającym danemu przykładowi rozkładem normalnym. Mamy:

$$S_n = \sum_{n=1}^N X_n \text{ gdzie, } X_n \text{ niezależne i każda z nich przyjmuje wartości } -1 \text{ lub } 1.$$

Najpierw obliczone zostaną wartość oczekiwana i odchylenie standardowe rozkładu normalnego przybliżającego S_n . Z niezależności:

$$\begin{aligned} \text{var}(S_n) &= \sum_{n=1}^N \text{var}(X_n) \\ \text{var}(X_n) &= E(X_n^2) - E(X_n)^2 \end{aligned}$$

$$E(X_n) = \frac{1}{2} * (-1) + \frac{1}{2} * 1 = 0$$


$$X_n^2 = 1 \text{ bo } X_n = \pm 1. \text{ Wi\c{e}c:}$$



$$\text{var}(X_n) = 1$$



$$\text{var}(S_n) = \sum_{n=1}^N \text{var}(X_n) = \sum_{n=1}^N 1 = N$$

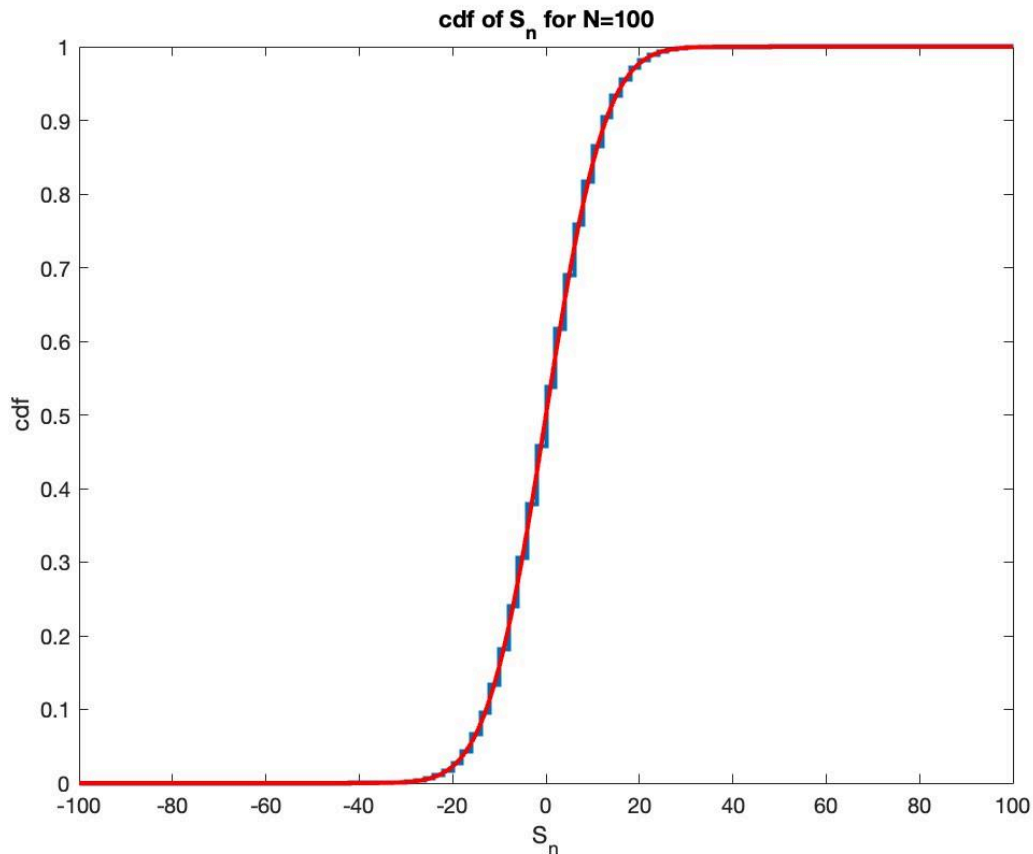
$$\sigma = \sqrt{N}$$

Następnie przygotowany został kod, który oblicza S_n . Wyniki tych numerycznych eksperymentów zostały przeniesione do Matlaba i obrobione - ostatecznie otrzymano 7 dystrybuant.









Z powyższych wykresów wyciągnąć można następujący wniosek:

Ponieważ podobna część wykresu S_n znajduje się zarówno nad jak i pod funkcją rozkładu normalnego (sytuacja ta przypomina w pewnym sensie aproksymację całką Riemanna), S_n jest dobrze przybliżana przez odpowiedni rozkład normalny:

$$\text{normaldistribution}(0, \sqrt{N})$$

Szczególnie ten wniosek jest prawdziwy dla dużych N - widać na wykresach, że wraz z wzrostem wartości N , schodki zbliżają się do funkcji.

3. Błądzenie losowe na liczbach całkowitych - rozkład czasu spędzonego nad osią OX

Trzeci podpunkt wymagał lekkiej modyfikacji napisanego już kodu do poprzedniego podpunktu, tak by rejestrował on czas gdy:


$$S_n > 0 \vee S_{n-1} > 0$$


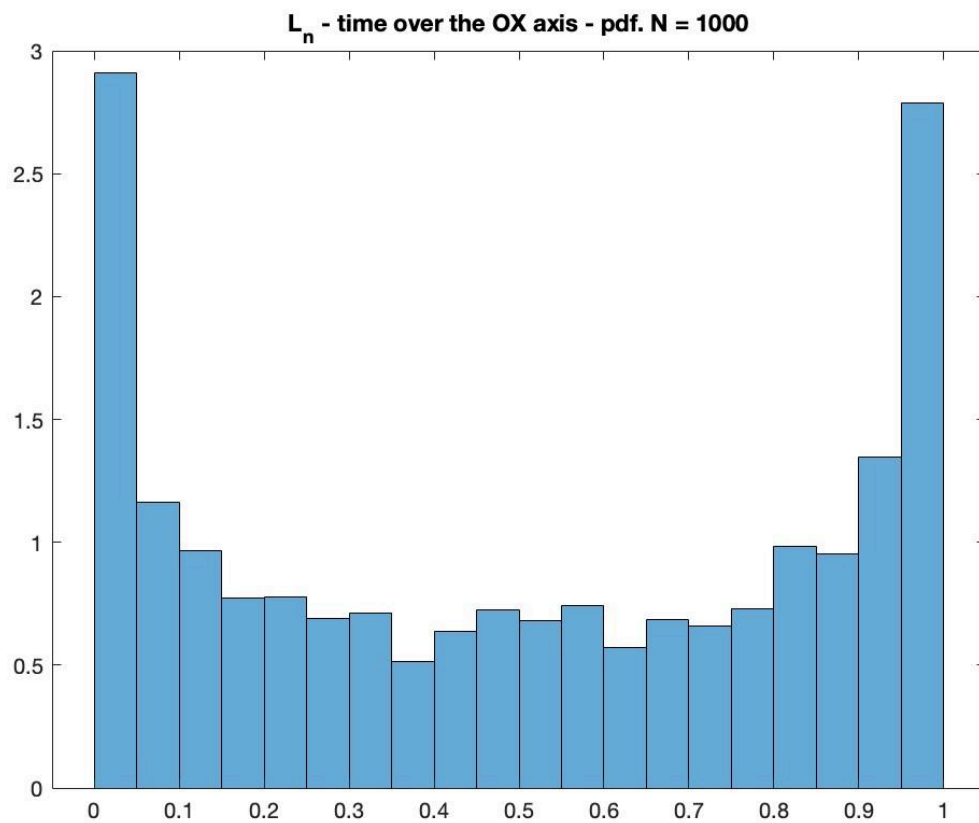
Zebrane eksperymentalnie stosunki - czasu spędzonego nad osią OX z łącznym czasem - zostały następnie wprowadzone do Matlaba, gdzie z użyciem funkcji histogram zostały znormalizowane, tak by prezentowały wartość pdf.

W celu zbadania zachowania zmiennej losowej w zależności od parametru N , wykonano trzy eksperymenty dla:

$$N \in \{100, 1000, 10000\}$$


Poniżej przedstawione zostały wykresy:





Na wykresach widać, że mają one powtarzalny trend i wartości. Jednakże, dla większych N odczyt się stabilizuje, szczególnie w centrum wykresu. Przypomina on wykres gęstości arcusa sinusa.

Porównując poniższy wykres z wynikami eksperymentu widzimy, że tak jak w przypadku podpunktu drugiego im większe n tym lepsza aproksymacja. Ewidentnie wraz z wzrostem n wartości układają się w łuk odwzorowujący funkcję arcus sinus..



1

Kajetan Plewa

¹ http://en.wikipedia.org/wiki/Arcsine_distribution#/media/File:Arcsin_density.svg [Accessed: 29.01.2025]